

Contenido

1. Contexto	2
2. Historia	2
3. Introducción	3
4. Variables aleatorias discretas	4
5. Función de distribución	6
6. Distribución de Bernoulli	8
7. Distrubución binomial	8
8. Distribución de Poisson	10
9. Aproximaciones.....	12
10. Aplicaciones.....	14
11. Conclusiones.....	15
12. Bibliografía.....	16
13. Posibilidades de ampliación	17

Índice + historia + introducción: 3 páginas

Tema: 13 páginas

Posibilidades de ampliación: 3 páginas

En este tema, conviene hablar (ver “posibilidades de ampliación”) de los momentos, y de la función generatriz, aunque sea someramente.

1. Contexto

- El tema pertenece al bloque de estadística (temas 57 a 68).
- El tema tiene relación con la distribución Normal (tema 66), que a su vez tiene relación con todos los temas de inferencia estadística y estadística y probabilidad en general. La distribución de Poisson, en cambio, aparece solo en este tema.
- En el currículo, encontramos la distribución binomial en los cursos de bachillerato (tanto Matemáticas I como Aplicadas), y en el Bachillerato Internacional (IB), tanto en nivel medio como superior. En el nivel superior, además, aparece la distribución de Poisson. En el bloque opcional de estadística aparecen, además, otras muchas distribuciones asociadas a estas (binomial inversa, hipergeométrica, etc.)

2. Historia

- Los primeros estudios sobre teoría de probabilidad se deben a Fermat y Pascal, y están asociados al azar en los juegos, en torno al SXVII.



- En el siglo XX, Kolmogorov formula la teoría axiomática de la probabilidad, estableciendo todas las bases que se utilizarán más adelante.



- Puede deberse la aparición de la distribución Binomial a James Bernoulli, alrededor del año 1670, aunque previamente Blaise Pascal ya había considerado el caso particular $p = 1/2$.



- La distribución de Poisson fue introducida por Siméon Denis Poisson en 1860, basándose en estudios previos de De Moivre.



3. Introducción

Denis está organizando una fiesta por su cumpleaños. Como es verano y sus amigos están cada uno en un sitio, decide llamarles uno a uno. Dado que repite el experimento cada año, poco a poco, se va dando cuenta de dos cosas:

- Hay una cierta probabilidad de que sus amigos le cojan el teléfono, pero quiere saber la probabilidad de que le cojan el teléfono un número determinado de amigos.
- Los que responden al teléfono suelen hacerlo una vez que el teléfono ha dado unos cuantos tonos de llamada. No suelen hacerlo al primer tono, ni al décimo, aunque a veces ocurre. Suele ocurrir al segundo, tercero o cuarto.

Por ello, Denis se plantea si quizá sería posible encontrar algún patrón para modelar matemáticamente tanto la primera como la segunda situación. ¿Cuál es la probabilidad de que le respondan un número determinado de amigos? Y ¿cuál es la probabilidad de que respondan antes de un tono determinado?

En este tema, además de intentar responder a las preguntas de Denis, haremos una breve introducción a las funciones de distribución y variables aleatorias discretas. Posteriormente nos ocuparemos de la distribución Binomial, previo paso por la distribución de Bernoulli. Describiremos la distribución de Poisson, y mostraremos algunas aplicaciones de ambas distribuciones. Finalizaremos el tema con el paso de las distribuciones discretas a las continuas en el caso de un número grande de experimentos.

4. Variables aleatorias discretas

Comenzaremos por definir el espacio probabilístico. Un espacio probabilístico es una terna $(\Omega, \mathcal{A}, p)$ donde $\mathcal{A}$ (a cuyos miembros llamaremos **sucesos**) es un σ álgebra del conjunto no vacío Ω (que llamaremos **espacio muestral**), y la función $p: \mathcal{A} \rightarrow \mathbb{R}$, llamada **probabilidad**, satisface que:

- i) $\forall M \in \mathcal{A}$ se tiene que $p(M) \geq 0$
- ii) La probabilidad $p(\Omega)$ del conjunto total vale 1.
- iii) Si $\{M_n; n \in \mathbb{N}\}$ es una familia de subconjuntos de $\mathcal{A}$ disjuntos dos a dos, la serie de término general $p(M_n)$ es convergente y se da la igualdad:

$$p\left(\bigcup_{n \in \mathbb{N}} M_n\right) = \sum_{n \in \mathbb{N}} p(M_n)$$

Recordemos que un σ -álgebra es una familia no vacía de subconjuntos de forma que si Ω es un conjunto no vacío, $\mathcal{A}$ es un σ -álgebra, si se cumplen las dos siguientes propiedades:

- o $\forall M \in \mathcal{A}$, el complementario $\bar{M} \in \mathcal{A}$.
- o Si M_n es una familia de elementos de $\mathcal{A}$, entonces $\bigcup_n M_n \in \mathcal{A}$

Veamos a continuación un ejemplo de espacio probabilístico. Tomemos una moneda no cargada (no trucada), y lancémosla dos veces. Es claro que:

- o El espacio muestral será $\Omega = \{CC, CX, XC, XX\}$
- o El σ álgebra tendrá $2^{\text{card}(\Omega)} = 2^4 = 16$ sucesos. Algunos de ellos, además de los cuatro anteriores, son $\emptyset, \{\{CC\}, \{CX\}\}$, o el propio Ω . Mostremos todos ellos (**no es recomendable hacer esto en el tema, no aporta nada**):

$$\left\{ \begin{array}{llll} A_1 = \emptyset & A_2 = \{CC\} & A_3 = \{XX\} & A_4 = \{CX\} \\ A_5 = \{XC\} & A_6 = \{CC, XX\} & A_7 = \{CC, XC\} & A_8 = \{CC, CX\} \\ A_9 = \{XX, XC\} & A_{10} = \{XX, CX\} & A_{11} = \{CX, XC\} & A_{12} = \{CC, CX, XC\} \\ A_{13} = \{CC, CX, XX\} & A_{14} = \{CC, XC, XX\} & A_{15} = \{XC, CX, XX\} & A_{16} = \{CC, CX, XC, XX\} \end{array} \right\}$$

- o La función de probabilidad p es tal que, por ejemplo, $p(\{CC\}) = 1/4$

Es obvio la conexión entre las leyes de probabilidad habituales y estas definiciones técnicas. Cuando hablamos de un suceso, como sacar un número par en un dado de seis caras, el suceso complementario, sacar un número impar, también debe pertenecer al espacio muestral (usualmente llamado E). Lo mismo ocurre con las uniones. Si tenemos el suceso números pares, y el suceso números primos, al unir ambos también debe pertenecer al espacio muestral (propiedad iii). El hecho de que la probabilidad sea siempre positiva o cero, siendo la probabilidad total 1, nos recuerda a la ley de Laplace, que muestra la probabilidad como un cociente, en el que el numerador y denominador son estrictamente positivos (casos posibles y totales), y el numerador debe ser igual o menor al denominador (los casos posibles no pueden superar a los totales).

En cuanto al σ -álgebra, las dos propiedades propuestas también nos conectan con lo conocido en cursos básicos. Por ejemplo, si se tiene el suceso “sacar un 2 en

un dado”, el suceso contrario, “no sacar un 2”, también debe estar en este álgebra. Nótese que “no sacar un 2” está en el álgebra, pero no implica sacar un 8 o un 9, que es imposible. Solo indica que “no sacar 2” debe pertenecer al álgebra. La segunda propiedad es inmediata del párrafo anterior.

Denotaremos en lo que sigue $\mathcal{B}$ al álgebra de Borel de la recta real $\mathbb{R}$. Se llama **σ álgebra de Borel** de la recta real $\mathbb{R}$ a la menor σ álgebra de $\mathbb{R}$ que contiene a los intervalos abiertos.

Una **variable aleatoria** definida en (Ω, A, p) es una función $u: \Omega \rightarrow \mathbb{R}$ tal que para cada $M \in \mathcal{B}$ se cumple que $u^{-1}(M) \in A$. Como la imagen representa uniones, intersecciones y complementarios, esto equivale a que $u^{-1}([a, b]) \in A$ para cada par de números reales a, b con $a \leq b$.

La función $p_u: \mathcal{B} \rightarrow \mathbb{R}$ definida por $p_u(M) = p(u^{-1}(M))$ es una **probabilidad**, llamada **inducida** en $(\mathbb{R}, \mathcal{B})$ por p y u .

Es inmediato que $p_u(M) = p(u^{-1}(M)) \geq 0$ y que $p_u(\mathbb{R}) = p(u^{-1}(\mathbb{R})) = p(\Omega) = 1$.

Además, si los conjuntos $\{N_n: n \in \mathbb{N}\} \subseteq \mathcal{B}$ son disjuntos dos a dos, también lo son los conjuntos $\{u^{-1}(N_n): n \in \mathbb{N}\}$, que pertenecen a A , y así:

$$p_u\left(\bigcup_{n \in \mathbb{N}} N_n\right) = p\left(u^{-1}\left(\bigcup_{n \in \mathbb{N}} N_n\right)\right) = p\left(\bigcup_{n \in \mathbb{N}} u^{-1}(N_n)\right) = \sum_{n \in \mathbb{N}} p(u^{-1}(N_n)) = \sum_{n \in \mathbb{N}} p_u(N_n)$$

Con todo esto, estamos en disposición de definir una **variable aleatoria discreta**, que será aquella que cumpla todo lo anterior, pero además su espacio muestral es un conjunto **finito** o **infinito numerable** de valores posibles, de forma que a cada suceso de Ω se le pueda hacer corresponder con un valor.

El ejemplo más sencillo es el lanzamiento de un dado de seis caras. El dominio de la variable aleatoria es $\Omega = \{1, 2, 3, 4, 5, 6\}$, es decir, un conjunto finito. Por tanto, la variable “lanzar un dado de seis caras y anotar el resultado”, es una variable aleatoria discreta.

El segundo ejemplo, menos evidente, puede ser el siguiente. Tenemos el suceso “sentarse en la montaña a contemplar estrellas fugaces, y anotar cuántas se han visto”. Es claro que sería raro, en una noche, ver un millar de estrellas fugaces, pero no es imposible. Tampoco dice el enunciado el tiempo de observación. Así pues, el espacio de sucesos, es decir, el número total de estrellas vistas, no tiene, en principio, cota superior, por lo que $\Omega = \mathbb{N}$, que es un conjunto infinito numerable. Por tanto, también es una variable discreta.

En cambio, nótese que si el experimento fuese “tiempo que pasa entre la observación de una estrella y la siguiente”, el espacio de sucesos sería $X = \mathbb{R}^+$ (en principio, incluyendo el cero, si asumimos la posibilidad de simultaneidad). Este es un conjunto **infinito no numerable**, en tanto que no podemos asignar a cada valor del tiempo una probabilidad. Este sería un ejemplo de variable aleatoria **continua**, que se ve en el tema siguiente.

Otra forma de ver una variable aleatoria discreta es como aquella cuya función de distribución es escalonada.

Para variables discretas, podemos definir la **esperanza matemática** como:

$$\mu(u) = \sum_{n \in \mathbb{N}} u_n p_u(u_n)$$

Se llama **momento de orden** $k \in \mathbb{N}$ de u , y se denota $\alpha_k(u)$ a la media de u^k , es decir:

$$\alpha_k(u) = E[u^k]$$

Así, por ejemplo, $\alpha_1(u) = \mu(u)$

Se llama momento central de orden $k \in \mathbb{N}$ de u , y se denota $\mu_k(u)$, al momento de orden k de la variable aleatoria $u - \mu(u)$, es decir:

$$\mu_k(u) = E[(u - \mu(u))^k]$$

El momento de orden 2 se denomina **varianza** de u .

Por último, es importante concretar las propiedades anteriores, para variables aleatorias generales, en el caso de tener una variable aleatoria discreta. Supondremos que nuestra variable tiene asociada una probabilidad, pero esta vez sobre el conjunto $\mathbb{N}$, de tal forma que el conjunto $\{p_i\}$, donde $i \in \mathbb{N}$, asocia la probabilidad p_i a cada elemento del conjunto. Así, se debe cumplir que:

$$i) \quad p_i \geq 0 \quad \forall i \in \mathbb{N}$$

$$ii) \quad \sum_{i=1}^{\infty} p_i = 1$$


Estas propiedades funcionan en ambos sentidos. Una variable aleatoria discreta debe cumplir estas propiedades. Pero si una variable cumple estas propiedades, entonces será variable aleatoria discreta. En el sumatorio se hace constancia de la numerabilidad del conjunto, en tanto que es posible sumar valores. En las variables continuas, cambiaremos la suma por la integral.

5. Función de distribución


Definamos la **función de probabilidad** $p(x)$ vista anteriormente, como aquella que asocia una probabilidad a cada elemento x del conjunto Ω . En el caso de una variable aleatoria discreta, esta función de probabilidad debe tener una forma discontinua, en tanto que el espacio de salida está compuesto por un conjunto finito o infinito numerable. Por ejemplo, la distribución de un dado de seis caras, en el experimento “anotar el número que sale al lanzar el dado”, podría definirse como:

$$f(x) = \begin{cases} \frac{1}{6} & x \in \{1,2,3,4,5,6\} \\ 0 & x \notin \{1,2,3,4,5,6\} \end{cases}$$


Gráficamente:



O, si se quiere representar mediante un diagrama de barras:



NOTA: imagen extraída del siguiente enlace, muy interesante para consulta:



Recordemos que una **función de distribución** es aquella que asocia a una variable X la probabilidad de que esta variable tome un valor igual o menor a un cierto x . También se le llama **función de distribución acumulada**, por este motivo.


En el caso de las variables aleatorias discretas, esta función, como mencionábamos antes, debe tener una estructura escalonada.

Por ejemplo, en el caso del dado anterior, la función sería:

$$F(x) = \begin{cases} 0 & x < 1 \\ \frac{[x]}{6} & x \in [1,6) \\ 1 & x \geq 6 \end{cases}$$

Donde $[x]$ es la función parte entera, es decir, el menor entero anterior a x .

Gráficamente:



Es sencillo ver en esta gráfica el concepto de variable aleatoria discreta frente a la continua. Si calculamos el área de esta función (integramos), es equivalente a sumar rectángulos.

6. Distribución de Bernoulli

Supongamos que realizamos un experimento en el cual los posibles resultados son el éxito, con probabilidad p , o el fracaso, con probabilidad q . Por ejemplo, esto podría ser lanzar chinchetas y que caigan hacia arriba o hacia abajo, o lanzar un dado y preguntarnos por la probabilidad de que salgan los números 1 y 2, o que salgan el resto de números. Esto es un experimento de Bernoulli, donde llamamos $q = 1 - p$ a la probabilidad de fracaso.

La esperanza de éxito viene dada por:

$$E[X] = \sum_x x \cdot p_x = 1 \cdot p + 0 \cdot q = p$$

Y la varianza será:

$$\text{Var}[X] = E[X^2] - (E[X])^2 = pq$$

Demostración:

$$\begin{aligned} \text{Var}[X] &= E[X^2] - (E[X])^2 = \sum_x x^2 p - \left(\sum_x x p \right)^2 = (1 \cdot p + 0 \cdot q) - (1 \cdot p + 0 \cdot q)^2 \\ &= p - p^2 = p(1 - p) = pq \end{aligned}$$

7. Distribución binomial

Supongamos ahora que tenemos varios experimentos de Bernoulli idénticos consecutivos, y nos preguntamos la probabilidad de obtener un cierto número k de éxitos. La probabilidad de realizar n experimentos y tener n éxitos es, obviamente:

$$p^k \cdot q^{n-k}$$

Ahora bien, podemos tener éxitos en los dos primeros experimentos (si buscamos dos éxitos) o en los dos últimos, o los dos intermedios. De esta forma, podemos ver que el número de formas en que podemos lograr los k éxitos son las **combinaciones** de los n experimentos tomados de k en k :

$$\binom{n}{k}$$

Así pues, llamaremos **binomial** de n experimentos con probabilidad de éxito p , y diremos que la variable X sigue una distribución binomial:

$$X \sim B(n, p)$$

La probabilidad de obtener k éxitos de entre los n experimentos será:

$$P(n = k) = \binom{n}{k} \cdot p^k \cdot q^{n-k}$$

Podemos extraer las siguientes propiedades de esta distribución:

Proposición: la esperanza matemática o media de la distribución Binomial es:

$$\mu = np$$

Demostración:

Una distribución Binomial Y no deja de ser la suma de n distribuciones de Bernoulli X , cada una con probabilidad p . Por propiedades de la esperanza matemática:

$$E[Y] = E[X + X + \dots + X] = E[X] + E[X] + \dots + E[X] = nE[X]$$

Dado que la esperanza de la distribución de Bernoulli es p , tenemos finalmente que la esperanza de la distribución binomial es:

$$\mu = np$$

Proposición: la varianza de la distribución Binomial es:

$$VAR = npq$$

Por lo que la desviación típica será:

$$s = \sqrt{npq}$$

Demostración:


Tomando la distribución de Bernoulli anterior, sabemos que $Var[Y] = pq$. Por tanto, dado que en la distribución binomial tenemos n experimentos similares:

$$Var[X] = Var[nY] = nVar[Y] = npq$$

De esta última expresión, vemos que la desviación típica será:

$$s = \sqrt{Var} = \sqrt{npq}$$

Por último, vemos que la distribución Binomial tiene un máximo en np (el valor más cercano, en caso de que $np \notin \mathbb{N}$), y a partir de ahí es tanto menos probable cuanto más nos alejamos de este valor central en cualquiera de las dos direcciones. Su dibujo aproximado es el siguiente:



Resulta inmediato ver que la función de distribución de esta variable viene dada por:

$$F(x) = P[X \leq x] = \begin{cases} 0 & x < 0 \\ \sum_{k=0}^x P[X = k] & 0 \leq x \leq n \\ 1 & x \geq n \end{cases}$$

$$F(x) = \begin{cases} 0 & x < 0 \\ \sum_{k=0}^x \binom{n}{k} p^k (1-p)^{n-k} & 0 \leq x \leq n \\ 1 & x \geq n \end{cases}$$

8. Distribución de Poisson

Consideremos ahora la probabilidad de que ocurra un cierto número de veces un suceso, en un determinado intervalo de tiempo (digamos, en una hora). Por ejemplo, imaginemos la aparición de un alumno por los pasillos de un colegio. Si imaginamos que la media de alumnos que aparecen por los pasillos es m cada hora, resulta razonable pensar que lo más frecuente es que aparezcan m alumnos, mientras que es tanto más improbable que aparezcan valores alejados por uno u otro lado de m . Esto se ajusta a una distribución de Poisson de media m , a cuya variable aleatoria diremos que se ajusta a:

$$X \sim Po(m)$$

y cuya probabilidad de que se produzcan k sucesos viene dada por:

$$P(x = k) = \frac{e^{-m} \cdot m^k}{k!}$$

Varias observaciones:

- Se ve claramente que, si la media es muy grande, la probabilidad tiende asintóticamente a cero. En efecto, si en un pasillo pasan muchos alumnos cada hora, la probabilidad de que pase un número finito (pequeño) de alumnos tiende a cero.
- Se tiene que:

Proposición: la función toma un máximo en $k = m$ y en $k = m - 1$, que será la moda de la distribución.

Demostración

En efecto, vemos los dos valores adyacentes a m (en el caso de variables discretas)

$$P(x = m) = \frac{e^{-m} \cdot m^m}{m!}$$

$$P(x = m - 1) = \frac{e^{-m} \cdot m^{m-1}}{(m-1)!} = \frac{e^{-m} \cdot m \cdot m^{m-1}}{m(m-1)!} = \frac{e^{-m} \cdot m^m}{m!} = P(x = m)$$

$$P(x = m - 2) = \frac{e^{-m} \cdot m^{m-2}}{(m-2)!} = \frac{m^2}{m^2} \cdot \frac{m(m-1)}{m(m-1)} \cdot \frac{e^{-m} \cdot m^{m-2}}{(m-2)!}$$

$$= \frac{m(m-1)}{m^2} \cdot \frac{e^{-m} \cdot m^m}{m!} = \frac{(m-1)}{m} P(x = m) < P(x = m)$$

$$P(x = m + 1) = \frac{e^{-m} \cdot m^{m+1}}{(m+1)!} = \frac{e^{-m} \cdot m \cdot m^m}{(m+1) \cdot m!} = \frac{m}{m+1} P(x = m) < P(x = m)$$

Vemos claramente como la probabilidad disminuye en $x = m + 1$ y en $x = m - 2$, mientras que, para valores enteros, se cumple que $P(x = m) = P(x = m - 1)$, siendo esta la moda.

- Observamos que es una función de distribución.
- Claramente podemos ver que todas las probabilidades son positivas, dada la positividad de la función exponencial, el factor m^k y la positividad del factorial.
- El sumatorio es igual a 1

Demostración:

En virtud del desarrollo de la función exponencial en serie de Taylor:

$$e^x = \sum_{i=0}^{\infty} \frac{x^i}{i!}$$

Se tiene entonces:

$$\sum_{k=0}^{\infty} P(x = k) = \sum_{k=0}^{\infty} \frac{e^{-m} m^k}{k!} = e^{-m} \underbrace{\sum_{k=0}^{\infty} \frac{m^k}{k!}}_{e^m} = e^{-m} \cdot e^m = 1$$

La esperanza matemática es $E(X) = m$

Demostración:

$$\begin{aligned} E(X) &= \sum_{k=0}^{\infty} k \cdot \frac{e^{-m} \cdot m^k}{k!} = e^{-m} \cdot \sum_{k=1}^{\infty} \frac{m^k}{(k-1)!} = e^{-m} \sum_{k=1}^{\infty} m \cdot \frac{m^{k-1}}{(k-1)!} \\ &= m \cdot e^{-m} \underbrace{\sum_{k'=0}^{\infty} \frac{m^{k'}}{k'!}}_{e^m} = m e^{-m} e^m = m \end{aligned}$$

- La varianza es $Var(X) = m$

Demostración:

$$\begin{aligned}
 \text{Var}(X) &= E(X^2) - (E(X))^2 = \sum_{k=0}^{\infty} k^2 \cdot \frac{e^{-m} m^k}{k!} - m^2 \\
 &= e^{-m} \sum_{k=1}^{\infty} k \cdot \frac{m^k}{(k-1)!} - m^2 \\
 &= e^{-m} \sum_{k=1}^{\infty} (k-1+1) \cdot \frac{m \cdot m^{k-1}}{(k-1)!} - m^2 \\
 &= m e^{-m} \sum_{k=1}^{\infty} (k-1) \cdot \frac{m^{k-1}}{(k-1)!} + m e^{-m} \underbrace{\sum_{k=1}^{\infty} \frac{m^{k-1}}{(k-1)!}}_{e^m} - m^2 \\
 &= m e^{-m} \sum_{k=1}^{\infty} \frac{m \cdot m^{k-2}}{(k-2)!} + m e^{-m} e^m - m^2 = m^2 + m - m^2
 \end{aligned}$$


Y finalmente:

$$\text{Var}(X) = m$$

Para graficar la distribución de Poisson no tenemos más que fijarnos en algunos detalles:

- $p(0) = e^{-m}$
- $\lim_{k \rightarrow \infty} p(k) = 0$
- El máximo se establece en los valores m y $m-1$ en variables discretas enteras, y en m en el resto de variables.

Con esto, queda dibujada la función (en el dibujo, tomamos λ como media en vez de m):



9. Aproximaciones

- Suele aceptarse que si la variable aleatoria binomial $u = B(n, p)$ es tal que si $n > 30$ y $np < 3$, entonces puede reemplazarse a efectos de cálculo por una variable de poisson $P(m)$, con parámetro la media $m = np$

Proposición: tenemos una variable $X \sim B(n, p)$, y asumamos que:

$$\begin{cases} n \rightarrow \infty \\ p \rightarrow 0 \end{cases}$$

Pero de tal forma que el producto permanece constante y no nulo. Entonces:

$$\lim_{\substack{n \rightarrow \infty \\ p \rightarrow 0}} P[X = x] = \frac{e^{-\lambda} \cdot \lambda^x}{x!}, \quad x = 0, 1, \dots$$

Donde $\lambda = np$. Es decir, $X \sim Po(\lambda)$

Demostración

$$P[X = x] = \binom{n}{x} \cdot p^x \cdot (1-p)^{n-x}$$

Si multiplicamos y dividimos entre n^x , una vez desarrollado el número combinatorio:

$$P[X = x] = \frac{n!}{x! \cdot (n-x)!} \cdot \frac{n^x}{n^x} \cdot p^x \cdot (1-p)^{n-x}$$

Combinamos $n!$ y $(n-x)!$, y n^x con p^x , de forma que:

$$P[X = x] = \frac{n \cdot (n-1) \cdot \dots \cdot (n-x+1)}{x! \cdot n^x} \cdot (np)^x \cdot (1-p)^{n-x}$$

Llamando $\lambda = np$ y reorganizando:

$$P[X = x] = \frac{n \cdot (n-1) \cdot \dots \cdot (n-x+1)}{n^x} \cdot \frac{\lambda^x}{x!} \cdot (1-p)^{n-x}$$

En la primera fracción, podemos aportar una n del denominador a cada término del numerador:

$$P[X = x] = \left[\frac{n}{n} \cdot \frac{n-1}{n} \cdot \dots \cdot \frac{n-x+1}{n} \right] \cdot \frac{\lambda^x}{x!} \cdot (1-p)^{n-x}$$

De forma que:

$$P[X = x] = \left[1 \cdot \left(1 - \frac{1}{n}\right) \cdot \dots \cdot \left(1 - \frac{x-1}{n}\right) \right] \cdot \frac{\lambda^x}{x!} \cdot (1-p)^{n-x}$$

Separando el último término $(1-p)^{n-x} = \frac{(1-p)^n}{(1-p)^x}$:

$$P[X = x] = \frac{1 \cdot \left(1 - \frac{1}{n}\right) \cdot \dots \cdot \left(1 - \frac{x-1}{n}\right)}{(1-p)^x} \cdot \frac{\lambda^x}{x!} \cdot (1-p)^n$$

En este punto, tomemos límites. En el caso en que $p \rightarrow 0$, es claro que $(1-p)^x$ debe tender a 1. No es tan claro que lo haga $(1-p)^n$, en tanto que $n \rightarrow \infty$. Por otro lado, dado que $n \rightarrow \infty$, el numerador de la primera fracción también tiende a 1. Veamos qué ocurre con $(1-p)^n$:

$$\lim_{\substack{n \rightarrow \infty \\ p \rightarrow 0}} (1-p)^n = \lim_{\substack{n \rightarrow \infty \\ p \rightarrow 0}} \left[(1-p)^{-\frac{1}{p}} \right]^{-np} = \lim_{\substack{n \rightarrow \infty \\ p \rightarrow 0}} \left[\left(1 + \frac{1}{-\frac{1}{p}} \right)^{\frac{1}{p}} \right]^{-np} = e^{-np} = e^{-\lambda}$$

Donde es importante recordar que hemos asumido que np , en el límite, es una cantidad finita no nula.

Con esto, tenemos que:

$$P[X = x] = \underbrace{\frac{1 \cdot \left(1 - \frac{1}{n}\right) \cdot \dots \cdot \left(1 - \frac{x-1}{n}\right)}{(1-p)^x}}_{\rightarrow 1} \cdot \frac{\lambda^x}{x!} \cdot \underbrace{(1-p)^n}_{\rightarrow e^{-\lambda}}$$

Y llegamos finalmente a:

$$P[X = x] = \frac{\lambda^x}{x!} \cdot e^{-\lambda}$$

Como se quería demostrar.

Por ejemplo, imaginemos que nuestra variable aleatoria consiste en llamar por teléfono a 10 amigos, y sabemos que la probabilidad de que respondan es $1/3$. En este caso, no se cumplen ninguna de las dos condiciones anteriores, y la aproximación no es buena. Ahora, si tenemos 50 amigos, y la probabilidad de que uno responda es $1/20$, tenemos que $m = 2.5 < 3$, y podemos utilizar una distribución de Poisson con esta media.

- Igualmente podemos hacer el salto a las variables continuas. Esto ocurrirá en caso en que $n \geq 30$, y podemos decir que una binomial $B(n, p)$ se aproxima en este caso razonablemente bien a una normal $N(\mu, \sigma)$, donde los parámetros de la misma son la media y desviación $\mu = np$ y $\sigma = \sqrt{npq}$.


En este mismo caso, se establece la **corrección de continuidad**, que dice que para un valor puntual de la variable discreta binomial, se tiene:

$$b(k, n, p) \approx \int_{k-0.5}^{k+0.5} N(x, np, \sqrt{npq}) dx$$

10. Aplicaciones

Las distribuciones de variable discreta, tanto las mencionadas como otras, como la geométrica, hipergeométrica, binomial inversa, etc, tienen numerosas aplicaciones en la vida real. Mencionemos algunas de ellas:

- Binomial
 - El aparato de Galton consiste en una serie de chinchetas por las que caen unas canicas (hay diversos modelos). Si todas están centradas, puede decirse que la probabilidad en cada salto de la canica es 0.5 a cada lado. Si las chinchetas no tienen simetría, podemos decir que tienen p al lado derecho, considerándolo como éxito, y $q = 1 - p$ al lado izquierdo.



Al tener diferentes niveles como muestra la figura, esto conforma una binomial. De esta forma, si el aparato fuese equilibrado, podríamos decir que merece la pena apostar a que la canica cae en el centro de la distribución, al haber mayor número de combinaciones que llevan a él. Si está desequilibrado, podemos calcular la mayor probabilidad de caída de una de las canicas.

- En realidad, casi toda la biología se basa en experimentos dicotómicos. Podemos tener bases nitrogenadas Adenina o Timina (A-T), o Guanina-Citosina. Según esto, el propio ADN y con ello toda la vida se basa en una sucesión enorme de experimentos dicotómicos (una normal, haciendo el paso al continuo). Esto explica por qué la normal aparece en tantos fenómenos biológicos.

- En la propia sociología, la mayoría de experimentos se basan en experimentos modelizables con experiencias dicotómicas. Por ejemplo, en una guerra los soldados pueden o no tener miedo, ser bien o mal guiados, estar bien o mal guarnecidos, etc. Todo esto hace que toda la sociología pueda modelizarse con sencillez con experimentos binomiales, aunque es más frecuente, dado que el número de experiencias suele ser grande, tomar directamente su versión con la distribución normal.
- Como ejemplos concretos de distribución binomial, podemos imaginar un submarino que dispara torpedos contra un objetivo con una probabilidad p de acierto de cada uno. Si nos preguntamos por la probabilidad de que acierten k de estos torpedos, esto sigue una distribución binomial.
- Distribución de Poisson

Esta es la distribución llamada de “fenómenos extraños”, en tanto a que obedece a una cierta regularidad de aparición de un fenómeno en concreto.

 - Cuando se mide el goteo de un grifo, este responde a una distribución de Poisson. Pongamos que el promedio de gotas que caen del grifo es G cada minuto. Es poco probable que caigan menos de G gotas cada minuto, siendo imposible que caigan gotas negativas. Además, cuantas más gotas nos preguntemos que caen por minuto, tanto menos probable será. Esto responde justo a una distribución de Poisson.
 - La vida media de las partículas en física responde a una distribución de Poisson. Las partículas elementales suelen tener un promedio de vida μ característico. Sin embargo, pueden tener algo más o algo menos, sin retroceder del cero, y aproximándose a cero a medida que nos preguntamos por vidas medias muy largas.
 - Otras aplicaciones de ambas son las enfermedades raras, la desintegración radiactiva, la precisión en la medida o los cultivos bacterianos.
 - Otras distribuciones: la distribución hipergeométrica (ver posibilidades de ampliación)

11. Conclusiones

Al cabo de muchos años y búsqueda de información, Denis ha recabado muchos datos sobre sus cumpleaños veraniegos en sus dos versiones:

- Al llamar a sus N amigos, Denis ha establecido que la probabilidad de que le cojan el teléfono es de p , basándose en los muchos experimentos realizados durante muchos años (ley de los grandes números). Por tanto, el número de personas que cogen el teléfono sigue una distribución binomial $B(N, p)$, siendo p la probabilidad de que le cojan el teléfono, y $q = 1 - p$ la de que no. Por tanto, si quiere que le cojan el teléfono al menos 4 amigos, para que tenga una fiesta, sabe que la probabilidad es:

$$P(x \geq 4) = 1 - P(x < 4) = 1 - [P(x = 0) + P(x = 1) + P(x = 2) + P(x = 3)]$$

Siendo cada una de las probabilidades:

$$P(x = k) = \binom{n}{k} \cdot p^k \cdot q^{n-k}$$

Así, Denis sabe de antemano la probabilidad de que se celebre la fiesta.

- Por otro lado, al llamar a sus amigos, ha determinado que en promedio le cogen el teléfono pasados m tonos. Esto se ajusta a una distribución de Poisson $Po(m)$, de forma que sabe que al llamar a cada uno de sus amigos, la probabilidad de que respondan antes de un determinado tono k , es:

$$P(x \leq k) = \sum_{i=0}^k \frac{e^{-m} \cdot m^i}{i!}$$

Pudiendo determinar así la probabilidad de que cada amigo le responda.

Con estos dos ejemplos vemos la utilidad de estas distribuciones. Hemos recorrido tanto las propiedades como las aplicaciones de las mismas. En lo que sigue sería interesante preocuparse por otras distribuciones de probabilidad, igualmente interesantes, como la geométrica (probabilidad de alcanzar el éxito pasados k experimentos), o la hipergeométrica (probabilidad de obtener un número de éxitos al realizar una serie de experimentos con probabilidad p , como por ejemplo resulta de calcular la probabilidad de éxito al estudiar m temas de los n posibles de una oposición, realizando k experimentos con probabilidad p).

12. Bibliografía

- The Joy of X, Steven Strogatz
- Apuntes temarios oposición.

13. Posibilidades de ampliación

- Existen varios teoremas que podrían tener cabida en este tema. Por ejemplo, el siguiente no es complicado de demostrar:

Proposición: dada X una variable aleatoria discreta, y $h(X)$ otra variable aleatoria, positiva, y tal que se puede calcular $E(h(X))$, entonces se cumple que, para todo $\varepsilon > 0$:

$$P[h(X) > \varepsilon] \leq \frac{E(h(X))}{\varepsilon}$$

Demostración

Tomemos el conjunto $A = \{x|h(x) \leq \varepsilon\}$, y $B = \{x|h(x) > \varepsilon\}$. Entonces:

$$\begin{aligned} E(h(X)) &= \sum_x h(x) \cdot P[X = x] = \sum_{x \in A} h(x) \cdot P[X = x] + \sum_{x \in B} h(x) \cdot P[X = x] \\ &\geq \sum_{x \in B} h(x) P[X = x] \end{aligned}$$

Ahora bien, a su vez, debe cumplirse que, dado que el conjunto B se compone de aquellos elementos para los cuales $h(x) > \varepsilon$, a lo sumo debería ser ε veces la suma de las probabilidades:

$$\sum_{x \in B} h(x) P[X = x] \geq \varepsilon \sum_{x \in B} P[X = x] = \varepsilon \cdot P[h(X) > \varepsilon]$$

Quedando completa la demostración, sin más que despejar.

- Toda la axiomática de la probabilidad tiene numerosos puntos que pueden ampliarse, como las funciones generadoras de momentos, o la función masa de probabilidad. A su vez, estas tienen teoremas que, quizá si uno tiene un conocimiento profundo de la probabilidad, le interese desarrollar.
- Por ejemplo, la **función generatriz** de momentos es tal que:

$$G_X(t) = E[e^{tX}]$$

Con ella, y mediante derivación, es posible el cálculo de los parámetros de las distribuciones. Por ejemplo, la esperanza matemática (la media), viene dada por:

$$E[X] = M_X^{(1)}(0) = \frac{d}{dt} M_X(0)$$

También sirven para variables continuas, cambiando las sumas por integrales.

Como ejemplo, calculemos la función generatriz de momentos de la distribución binomial $X \sim B(n, p)$. Para ello:

$$M_X(t) = E[e^{tX}] = \sum_{x=0}^n e^{tx} \binom{n}{x} \cdot p^x \cdot q^{n-x} = \sum_{x=0}^n \binom{n}{x} \cdot (pe^t)^x \cdot (1-p)^{n-x}$$

Puede demostrarse que esto es igual a:

$$M_X(t) = [e^t p + (1-p)]^n$$

Por ejemplo, si probamos a derivar esta expresión, y evaluamos en $t = 0$, tenemos la media:

$$M'_X(t) = n \cdot [e^t p + 1 - p]^{n-1} \cdot e^t p$$

Evaluyendo en $t = 0$:

$$M'_X(t) = n \cdot [p + 1 - p]^{n-1} \cdot p = n \cdot [1]^{n-1} \cdot p = n \cdot p$$

Como es de sobra conocido.

- Se ha descartado hablar de los **momentos**, de los cuales la media es el de orden 1, y la varianza de orden 2. Se puede ampliar el tema con ellos. Un momento centrado en un punto c de orden n , viene dado por:

$$m_n = E[(X - c)^n] = \sum_{k=1}^N p_k (x_k - c)^n$$

Nótese que la media no es más que un momento de orden 1 centrado en $c = 0$:

$$m_{1,c=0} = \sum_{k=1}^N p_k x_k$$

Mientras que la varianza es el momento de orden 2 centrado en la media:

$$VAR = \sum_{k=1}^N p_k (x_k - \mu)^2$$

Siendo $\mu = E[X]$

- Existen varios resultados y teoremas que se pueden mencionar, y demostrar. Entre ellos, puede mencionarse la desigualdad de Markov, o la de Tchebyshev.
- Hay otros parámetros en una distribución de los que no se habla, pero que se podrían introducir, como son los de asimetría y los de curtosis, relacionados con momentos de orden superior.
- Existen otras distribuciones de probabilidad de variable discreta. Mencionamos (aunque quizá no es necesario incluirlo en el tema, o solo mencionarlo), la distribución hipergeométrica, por su conexión con el proceso opositor.

$$X \sim HG\left(N, d, \frac{D}{N}\right)$$

En esta distribución, se tienen N elementos (como los 71 temas del temario), de los cuales A de ellos pertenecen a una categoría (los temas estudiados), y B a otra (los no estudiados), de forma que obviamente que $A + B = N$.

La distribución hipergeométrica permite calcular la probabilidad de obtener un número x de elementos de la clase A , donde $x \in [0, d]$, en una muestra **sin** reemplazo de n elementos de la población original. Esta probabilidad viene dada por:

$$P(X = x) = \frac{\binom{d}{x} \cdot \binom{N-d}{n-x}}{\binom{N}{n}}$$

El valor esperado y desviación vienen dado por:

$$E = \frac{nd}{N} \quad \sigma = \sqrt{\frac{N-n}{N-1} \cdot \frac{nd}{N} \cdot \left(1 - \frac{d}{N}\right)}$$

Como ejemplo evidente, calculemos la probabilidad de, habiendo estudiado 23 temas de un total de 71, que salga uno, extrayendo 5 temas:

$$\begin{cases} N = 71 \\ d = 23 \\ n = 5 \\ x = 1 \end{cases} \Rightarrow P(X = 1) = \frac{\binom{5}{1} \cdot \binom{71-5}{23-1}}{\binom{71}{23}} = \frac{\binom{5}{1} \cdot \binom{66}{22}}{\binom{71}{23}} = 0.34$$

Ahora bien, también nos interesa la probabilidad de que salgan 2 temas que nos sabemos, 3, 4 o 5. Cambiando x por cada una, tenemos:

$$P(X = 1) + P(X = 2) + \dots + P(X = 5) = 0.34 + 0.33 + 0.15 + 0.03 + 0.003$$

Dando finalmente que la probabilidad de que toque un tema de los 71, escogiendo 5 bolas, y habiendo estudiado 23 temas, es:

$$P(1 \leq X \leq 5) = 0.86848$$

Que es, en nuestra opinión, una probabilidad muy razonable según el número de temas estudiados.

○ Otras distribuciones discretas son:

- Distribución geométrica: $X \sim Ge(p)$, que describe el proceso de realizar un número de experimentos independientes de probabilidad de éxito p , hasta obtener el primer éxito:

$$P[X = k] = (1 - p)^{k-1} \cdot p, \quad E[X] = \frac{1}{p}, \quad VAR[X] = \frac{1 - p}{p^2}$$

- Distribución binomial negativa: $X \sim BN(r, p)$, que consiste en describir el número de fracasos de un experimento dicotómico de probabilidad de éxito p , antes del r -ésimo éxito:

$$P[X = k] = \binom{r+k-1}{r-1} \cdot p^r \cdot (1-p)^k, \quad E[X] = \frac{r(1-p)}{p},$$

$$VAR[X] = \frac{r(1-p)}{p^2}$$