

Contenido

1. Contexto	2
2. Historia	2
3. Introducción	3
4. Conceptos previos. Variables aleatorias continuas (reutilizado en el tema 65) 4	
5. Función de distribución y función de densidad.....	5
6. Propiedades de las variables aleatorias continuas	7
7. Distribución normal.....	9
7.1. Definiciones y propiedades.....	9
7.2. Tipificación de la variable	13
7.3. Teorema central del límite	15
7.4. Aproximación de la binomial por la normal.....	15
8. Aplicaciones	16
9. Conclusión.....	18
10. Bibliografía.....	18
11. Posibilidades de ampliación.....	18

1. Contexto

- El tema pertenece al bloque de estadística (temas 57 a 68).
- El tema tiene relación con las distribuciones de variable discreta (tema 65), que a su vez tiene relación con todos los temas de inferencia estadística y estadística y probabilidad en general.
- En el currículo, encontramos la distribución normal en los cursos de bachillerato (tanto Matemáticas I como Aplicadas), y en el Bachillerato Internacional (IB), tanto en nivel medio como superior.

2. Historia


- Los primeros estudios sobre teoría de probabilidad se deben a Fermat y Pascal, y están asociados al azar en los juegos, en torno al SXVII.



- Es De Moivre el que aplica primero el teorema central del límite para hacer el paso de la binomial a la que luego será llamada normal, en 1733. En 1809 Gauss utiliza recurrentemente esta distribución (que acabará adoptando su nombre), al estudiar los errores, fundamentalmente derivados de observaciones astronómicas.



- En 1810 Laplace expone el desarrollo de la teoría en su análisis matemático sobre los juegos de azar. En la primera mitad del SXX Andréi Kolmogorov establece la axiomática de la estadística y la probabilidad como la conocemos hoy.



3. Introducción

Abraham lleva todo el año estudiando concienzudamente matemáticas. En un momento dado se da cuenta que sus periodos de concentración suelen durar aproximadamente unos 45 minutos (casi media hora más que la mayor parte de la población), y decide elaborar un estudio global, tanto en su caso como en el de otros compañeros. Resulta que es bastante poco probable que alguien se concentre bien más de 35 minutos ni menos de 15, y a partir de ahí la probabilidad cae en picado en ambos lados. Así pues, se decide a confeccionar una tabla registrando los tiempos, y cada día realiza la media y la desviación de estos periodos de estudios, encontrándose con una curiosa figura simétrica con un máximo en 25.

Por otro lado, su compañero Carl decide preguntarse por la probabilidad de que algunos de sus compañeros estén o no estudiando. Ya dedujo en su momento que esto llevaría a una distribución binomial, en tanto que es una dicotomía. El caso es que Carl tiene muchos amigos. Por ello, cada cierto tiempo, encuesta masivamente a todos sus compañeros para saber si están o no estudiando, y anota los datos. Al representar la probabilidad de que un número n de amigos estén estudiando, se encuentra con una curva muy parecida a la de su amigo Abraham. ¿Qué está ocurriendo?

En este tema comenzaremos definiendo las bases de la probabilidad, para seguir explicando qué es una distribución de probabilidad (concretamente, una continua), y sus parámetros. Con esto llegaremos al caso particular de la distribución normal. Por último, mostraremos el teorema central del límite, que permite pasar de una distribución discreta como la Binomial a una continua como la Normal en el caso de que el número de experimentos sea grande.

Ya, con esto, podremos dar respuesta a Abraham y a Carl.

4. Conceptos previos. Variables aleatorias continuas (reutilizado en el tema 65¹)

Antes de comenzar a desarrollar los conceptos de este tema, resumamos someramente las bases de la probabilidad con algunas definiciones formales (aunque esto realmente pertenece a los temas de probabilidad anteriores):

Definición: llamaremos **experimento aleatorio** a aquel del que no podemos predecir, a priori, su resultado².

Definición: llamaremos **espacio muestral** Ω al conjunto formado por todos los posibles resultados de un experimento aleatorio. Llamaremos **sucesos elementales** a cada uno de los elementos de este conjunto.

Desde este punto de vista, un espacio muestral puede ser **discreto** o **continuo**, según cómo sea la naturaleza de dicho conjunto. En este tema abordaremos el caso de los espacios muestrales **continuos**, que son conjuntos infinitos no numerables³, como el caso que nos ocupa, los reales $\mathbb{R}$.

Si tomamos una colección de subconjuntos Σ del espacio muestral, será un σ álgebra⁴ si cumple:

- i) Contiene al conjunto completo, es decir, $\Omega \in \Sigma$
- ii) Es cerrada bajo complementarios, es decir, si $A \in \Sigma$, entonces su complementario $\bar{A} \in \Sigma$.
- iii) Es cerrada bajo uniones numerables, es decir, si tenemos una secuencia de conjuntos $A_n \in \Sigma$, con $n = 1 \dots \infty$, entonces su unión $\bigcup_{n=1}^{\infty} A_n \in \Sigma$

Sobre esta σ álgebra será sobre la que construiremos las bases de la probabilidad. Tomaremos una función p que actúa sobre los elementos del σ álgebra, de la forma:

¹ Marcamos en rojo las diferencias entre el T65 y T66, para que puedas reutilizarlo.

² Existe mucha literatura, y mucha filosofía, con esto, ya que, aunque es sencillo expresar informalmente qué es la probabilidad, no es nada fácil establecerlo rigurosamente. Hipotéticamente, si pudiésemos controlar todas las variables (temperatura y presión del aire, fuerza, ángulo y velocidad del lanzamiento de moneda, etc.), podríamos hipotéticamente predecir qué ocurrirá en el lanzamiento de un dado. Mientras que un experimento determinista está bien definido (por ejemplo, una máquina sumadora, que siempre que recibe, por ejemplo, un 1 y un 2, el resultado es 3), no está tan clara la barrera que separa el determinista del no determinista. En último caso, por ejemplo, la propia naturaleza, desde sus teorías de la Mecánica Cuántica, sí es completamente probabilística (que es lo que contrariaba a Einstein), mientras que podríamos decir que el lanzamiento de una moneda se puede considerar como aleatorio.

³ Recordemos que un conjunto numerable es aquel que puede ponerse en correspondencia con los naturales. No hay que confundir con los conjuntos densos. Por ejemplo, los racionales pueden ponerse en correspondencia con los naturales (tienen la misma cardinalidad $\aleph_0$ que los naturales), así que es un conjunto numerable. Sin embargo, también es un conjunto denso, en tanto que entre dos racionales podemos encontrar infinitos racionales.

⁴ La necesidad de todo esto viene de las tres definiciones clásicas de probabilidad, a saber, la **subjettiva**, la **clásica** y la **frecuentista**, cada una de ellas con ciertas limitaciones. Fue Kolmogorov quien estableció unos axiomas y definiciones para dotar de estructura lógica a la probabilidad, que son, resumidos, los que mostramos aquí.

$$\begin{aligned} p: \Sigma(\Omega) &\rightarrow [0,1] \\ A &\mapsto p(A) \end{aligned}$$

Que debe cumplir los **axiomas de Kolmogorov**:

- i) $p(A) \geq 0 \quad \forall A \in \Sigma(\Omega)$
- ii) $p(\Omega) = 1$
- iii) Dada una colección de elementos **disjuntos** de $\Sigma(\Omega)$, A_n :

$$p\left(\bigcup_{n=1}^N A_n\right) = \sum_{n=1}^N p(A_n)$$

Con esto ya podemos finalmente enunciar formalmente:

Definición: a la terna (Ω, Σ, p) , con las definiciones, propiedades y axiomas establecidos anteriormente, la definiremos como un **espacio probabilístico**⁵.

En lo que sigue tomaremos un espacio probabilístico, como el que acabamos de explicar, una variable aleatoria $X: \Omega \rightarrow \mathbb{R}$ en el espacio probabilístico (Ω, Σ, p) , y con una función probabilidad $p: \Sigma \rightarrow \mathbb{R}$, que cumple que $0 \leq p(A) \leq 1$, dándose $p(\Omega) = 1$.

Definición: diremos que una variable aleatoria es **continua** si el espacio muestral del espacio probabilístico sobre el que está definida es un conjunto infinito no numerable.

El ejemplo más sencillo es una variable que describa, por ejemplo, en un experimento que sea “sentarse en la montaña a contemplar estrellas”, la variable X dada por “tiempo que pasa entre la observación de una estrella y la siguiente”, el espacio de sucesos sería $X = \mathbb{R}^+$ (en principio, incluyendo el cero, si asumimos la posibilidad de simultaneidad). Este es un conjunto **infinito no numerable**, en tanto que no podemos asignar a cada valor del tiempo una probabilidad. Este sería un ejemplo de variable aleatoria **continua**.

En el tema anterior, vimos **variables aleatorias discretas**, que, en contraposición, requieren un conjunto finito (lanzamiento de un dado, $\Omega = \{1,2,3,4,5,6\}$), o infinito numerable (“anotar cuántas estrellas fugaces se han visto”, $\Omega = \mathbb{N}$).

5. Función de distribución y función de densidad

Definición: se llama **función de distribución de la variable continua X** a la función:

$$\begin{aligned} F: \mathbb{R} &\rightarrow \mathbb{R} \\ x &\mapsto p((-\infty, x]) \end{aligned}$$

Es frecuente usar, y así lo haremos, $P(X \leq x)$ y cumple:

- i) Es creciente, continua por la derecha, e $Im F \subseteq [0,1]$

⁵ Nótese la cantidad de cuestiones adicionales que se podrían mencionar aquí, y no hemos hecho. Por ejemplo, definir el suceso imposible, la unión e intersección de sucesos, etc. No obstante, esto es una breve introducción para establecer que partimos de unos axiomas y una serie de propiedades, para poder enunciar posteriormente las funciones de distribución. Puedes completar con lo que consideres oportuno, pero no te salgas demasiado del tema.

$$\text{ii)} \quad \lim_{x \rightarrow -\infty} F = 0, \lim_{x \rightarrow \infty} F = 1$$

Es fácil comprobar que toda función que satisfaga estas dos condiciones es función de distribución.

Definición: Se llama **función de densidad** a la función $f: \mathbb{R} \rightarrow [0,1]$, tal que para cada par de números $a, b \in \mathbb{R}$, con $a \leq b$ se tiene:

$$p([a, b]) = \int_a^b f(t) dt$$

Asociando una probabilidad a cada intervalo $I: [a, b]$. De las propiedades de la integral definida deducimos que, dado que:

$$F(x) = \int_{-\infty}^x f(t) dt$$

Entonces la función F es continua y derivable en aquellos puntos que lo es f . Además, el hecho de que F sea no decreciente asegura que $f(x) \geq 0$. Además:

$$\int_{-\infty}^{\infty} f(t) dt = \lim_{x \rightarrow \infty} \int_{-\infty}^x f(t) dt = \lim_{x \rightarrow \infty} F(x) = 1$$

El recíproco es válido. Toda función que toma valores no negativos con la condición anterior es función de densidad. Así pues, la función de densidad, para serlo, debe cumplir⁶:

$$\text{i)} \quad f(x) \geq 0 \quad \forall x \in \mathbb{R}$$

$$\text{ii)} \quad \int_{-\infty}^{\infty} f(x) dx = 1$$

Y cualquier función $f(x)$ que cumpla estos dos preceptos es la función de densidad de alguna variable aleatoria continua. Por otro lado, es inmediato comprobar que probabilidades de sucesos puntuales son nulas, en tanto que:

$$P[X = a] = \int_a^a f(x) dx = 0$$

Ejemplo: supongamos la siguiente función, con $\alpha \in \mathbb{R}, \alpha > 0$:

$$f(x) = \begin{cases} 0 & x \notin [1, 2] \\ \alpha(x-1) & x \in [1, 2] \end{cases}$$

Vemos que claramente cumple que es definida positiva o nula, tiende a cero en infinito, y falta por comprobar que su área (integral) es 1:

$$\begin{aligned} \lim_{x \rightarrow \infty} F(x) &= \lim_{x \rightarrow \infty} \int_{-\infty}^x f(t) dt = \int_1^2 f(t) dt = \int_1^2 \alpha(t-1) dt = \alpha \left(\frac{t^2}{2} - t \right)_1^2 \\ &= \alpha \left(0 - \left(-\frac{1}{2} \right) \right) = \frac{\alpha}{2} \end{aligned}$$

Por tanto, siempre que la constante $\alpha = 2$, la función anterior será una función de densidad. Su función de distribución asociada será:

$$F(x) = \int_{-\infty}^x f(t) dt = \dots = \alpha \left(\frac{t^2}{2} - t \right)_1^x = \alpha \left(\frac{x^2}{2} - x + \frac{1}{2} \right)$$

Con $\alpha = 2$ para que se cumpla la hipótesis anterior.

⁶ Puede añadirse, como tercera condición, que la función tenga a lo sumo una cantidad numerable de discontinuidades, para que sea integrable Riemann.

Ejemplo 2: una de las distribuciones continuas más sencillas es la **distribución uniforme**, que viene dada por:

$$f(x) = \begin{cases} k & x \in [a, b] \\ 0 & x \notin [a, b] \end{cases}$$

Para que sea función de densidad, debe cumplir que:

$$\int_{-\infty}^{\infty} f(x) dx = \int_a^b k \cdot dx = [kx]_a^b = k(b-a) = 1$$

De donde vemos que la función debe tener la forma general:

$$f(x) = \begin{cases} \frac{1}{b-a} & x \in [a, b] \\ 0 & x \notin [a, b] \end{cases}$$

De aquí, es fácil ver que la función de distribución será:

$$F(x) = \begin{cases} 0 & x < a \\ \frac{x-a}{b-a} & x \in [a, b] \\ 1 & x \geq b \end{cases}$$

6. Propiedades de las variables aleatorias continuas

Para una variable aleatoria continua con función de densidad f , definimos:

Definición: se llama **media o esperanza matemática** de una variable aleatoria continua a:

$$\mu \equiv E(X) = \int_{-\infty}^{\infty} t \cdot f(t) dt$$

Definición: se llaman **momentos de orden k** de una variable aleatoria continua al número real:

$$\alpha_k(X) = \int_{-\infty}^{\infty} t^k f(t) dt$$

O lo que es lo mismo:

$$\alpha_k(X) = E(X^k)$$

Desde este punto de vista, la media o esperanza es el momento de orden 1

$$\alpha_1(X) = \mu$$

Definición: se llaman **momentos de orden k respecto a la media o momento central** de una distribución aleatoria continua a:

$$\mu_k(X) = \int_{-\infty}^{\infty} (t - \mu)^k f(t) dt$$

O lo que es lo mismo:

$$\mu_k(X) = E[(X - \mu)^k]$$

Puede comprobarse que el momento de orden 1 respecto a la media es idénticamente cero, por definición.

Definición: se llama **varianza** al momento central de orden 2:

$$VAR(X) \equiv \mu_2(X) = \int_{-\infty}^{\infty} (t - \mu)^2 f(t) dt$$

Que puede comprobarse que está definido no negativo. Puede expresarse también como:

$$VAR(X) = E[(X - \mu)^2]$$

Definición: dado que la varianza está definida no negativa, se llama **desviación típica σ** a la raíz cuadrada de la varianza:

$$\sigma = \sqrt{VAR(X)}$$

Este parámetro da una idea de la dispersión de la distribución respecto a la media. Si la variable aleatoria la medimos en unas ciertas unidades u , podemos ver que las dimensiones de la media serán las mismas que las de la desviación, de ahí la utilidad de este parámetro.

Proposición: la varianza $VAR(X)$ cumple:

$$VAR(X) = \alpha_2(X) - \mu^2 \Rightarrow VAR(X) = E(X^2) - [E(X)]^2$$

Demostración:

$$\begin{aligned} VAR(X) &= \int_{-\infty}^{\infty} (t^2 f(t) + \mu^2 f(t) - 2\mu t f(t)) dt \\ &= \int_{-\infty}^{\infty} t^2 f(t) dt + \mu^2 \int_{-\infty}^{\infty} f(t) dt - 2\mu \int_{-\infty}^{\infty} t \cdot f(t) dt \\ &= \alpha_2(X) + \mu^2 - 2\mu \cdot \mu = \alpha_2(X) - \mu^2 \end{aligned}$$

Esta expresión también puede mostrarse como:

$$VAR(X) = E(X^2) - [E(X)]^2$$

Proposición: destacamos las dos siguientes propiedades de la esperanza y la varianza. Para dos números $a, b \in \mathbb{R}$:

i) $E(aX + b) = aE(X) + b$

ii) $VAR(aX + b) = a^2 \cdot VAR(X)$

Demostración i:

Su demostración es trivial a partir de la definición:

$$E(aX + b) = \int_{\mathbb{R}} (ax + b) \cdot f(x) dx = a \int_{\mathbb{R}} x \cdot f(x) dx + b \int_{\mathbb{R}} f(x) dx = aE(X) + b$$

Demostración ii:

Su demostración es trivial a partir de la definición:

$$\begin{aligned} VAR(aX + b) &= E[(aX + b)^2] - E[aX + b]^2 \\ &= E[a^2 X^2 + b^2 + 2aXb] - (aE[X] + E[b])^2 \\ &= E[a^2 X^2] + E[b^2] + E[2aXb] - (a^2 E[X]^2 + E[b]^2 + 2aE[X]E[b]) \end{aligned}$$

Donde hemos usado la propiedad de linealidad de integrales (o bien la propiedad i)

$$\begin{aligned} VAR(aX + b) &= a^2 E[X^2] + E[b^2] + 2abE[X] - a^2 [E[X]]^2 - E[b]^2 - 2aE[X]E[b] \\ VAR(aX + b) &= a^2 E[X^2] + b^2 + 2ab\mu - a^2 \mu^2 - b^2 - 2a\mu b \end{aligned}$$

Llegamos finalmente a:

$$VAR(aX + b) = a^2 E[X^2] - a^2 \mu^2 = a^2 (E[X^2] - \mu^2) = a^2 VAR(X)$$


En cuanto a otros parámetros de la distribución, es frecuente definir la mediana, como valor central, así como los cuartiles, que en este caso:

Definición: definimos **mediana** de una distribución continua, a aquel valor m que cumple:

$$\int_{-\infty}^m f(x) dx = 0.5$$

Definimos igualmente los **cuartiles** $q_i, i = 1, 2, 3$, como aquellos valores que se definen igual que la mediana, pero con probabilidad 0.25, 0.5 (la mediana), y 0.75 respectivamente.

Estos tres valores son los que dejan detrás de sí al 25%, 50% y 75% de la distribución, y permiten crear los **diagramas de cajas y bigotes**, a veces llamados **diagramas de los cinco puntos**, que visualmente dan mucha información sobre una distribución:



(Imagen extraída de este [enlace](#))

Por último, mencionamos un importante tratamiento de las variables continuas, aunque en este tema apenas lo usaremos por falta de tiempo:

Definición: dada una variable aleatoria continua X , se llama **función generadora de momentos** $M(t)$, a la función dada por:

$$M(t) = E(e^{tX}) = \int_{\mathbb{R}} e^{tx} f(x) dx$$

Conociendo la función generadora de momentos de cada distribución, es posible obtener de ella numerosos resultados. Por ejemplo, es fácil comprobar que los momentos vienen dados por:

$$E[X^n] = \left[\frac{d^n}{dt^n} M(t) \right]_{t=0}$$

7. Distribución normal

7.1. Definiciones y propiedades

Dentro de las distribuciones continuas, como la que vimos en el ejemplo al principio, existen algunas que, por su importancia, merece la pena destacar. La distribución normal es una de ellas.

Definición: dados dos números reales $\mu, \sigma > 0$, se considera la función C^∞ , y se llama **distribución normal o gaussiana**, a:

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} \exp \left[-\frac{(x - \mu)^2}{2\sigma^2} \right]$$

Es obvio que cumple las primeras propiedades de función de densidad, pues es definida positiva (por la exponencial), y tiende a cero en los extremos.

Proposición: dada una distribución normal, como distribución que es, cumple:

$$\int_{\mathbb{R}} f(x) dx = 1$$

Demostración 1:

Tomemos las dos siguientes integrales, que en realidad son la misma:

$$I = \int_{-\infty}^{\infty} \frac{1}{\sigma\sqrt{2\pi}} \exp\left[-\frac{(x-\mu)^2}{2\sigma^2}\right] dx$$

$$I = \int_{-\infty}^{\infty} \frac{1}{\sigma\sqrt{2\pi}} \exp\left[-\frac{(y-\mu)^2}{2\sigma^2}\right] dy$$

Multiplicando ambas y utilizando propiedades de la exponencial, y el teorema de Fubini:

$$I^2 = \left(\frac{1}{\sigma\sqrt{2\pi}}\right)^2 \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} \exp\left[-\frac{(x-\mu)^2 + (y-\mu)^2}{2\sigma^2}\right] dx dy$$

Hagamos el cambio:

$$\begin{cases} x = \rho \cos\theta + \mu \\ y = \rho \sin\theta + \mu \end{cases}$$

Con el jacobiano de las coordenadas polares $J = \rho$, de forma que:

$$I^2 = \left(\frac{1}{\sigma\sqrt{2\pi}}\right)^2 \int_0^{2\pi} \int_0^{\infty} \rho \exp\left[-\frac{\rho^2}{2\sigma^2}\right] d\rho d\theta$$

Integrando:

$$I^2 = \left(\frac{1}{\sigma\sqrt{2\pi}}\right)^2 \int_0^{2\pi} (-\sigma^2) \exp\left[-\frac{\rho^2}{2\sigma^2}\right]_0^{\infty} d\theta = \left(\frac{1}{\sigma\sqrt{2\pi}}\right)^2 \int_0^{2\pi} (\sigma^2) d\theta$$

Integrando ahora en θ :

$$I^2 = \frac{1}{2\pi} \cdot \theta_0^{2\pi} = \frac{2\pi}{2\pi} = 1 \Rightarrow \boxed{I=1}$$

Demostración 2⁷:

Comencemos por el siguiente cambio de variable:

$$z = \frac{x-\mu}{\sigma} \Rightarrow dz = \frac{1}{\sigma} dx$$

Con lo que:

$$I = \int_{-\infty}^{+\infty} \frac{1}{\sigma\sqrt{2\pi}} \exp\left[-\frac{(x-\mu)^2}{2\sigma^2}\right] dx = \int_{-\infty}^{+\infty} \frac{\sigma}{\sigma\sqrt{2\pi}} \exp\left[-\frac{z^2}{2}\right] dz$$

Eliminamos σ . Vemos que tenemos una función par, por lo que:

$$I = \frac{2}{\sqrt{2\pi}} \int_0^{\infty} \exp\left[-\frac{z^2}{2}\right] dz$$

Y volvemos a cambiar la variable:

$$t = \frac{z^2}{2} \Rightarrow dt = z dz \Rightarrow dz = \frac{1}{z} dt = \frac{1}{\sqrt{2t}} dz$$

$$\Rightarrow I = \frac{2}{\sqrt{2\pi}} \int_0^{\infty} \frac{1}{\sqrt{2t}} \exp(-t^2) \cdot dt = \frac{1}{\sqrt{\pi}} \int_0^{\infty} t^{-1/2} \cdot \exp(-t) \cdot dt$$

Pero esto es una integral tipo Gamma:

$$\Gamma(p) = \int_0^{\infty} x^{p-1} \cdot e^{-x} dy$$

En nuestro caso, con $p = 1/2$, por lo que, con propiedades de la gamma:

$$I = \frac{1}{\sqrt{\pi}} \cdot \Gamma\left(\frac{1}{2}\right) = \frac{1}{\sqrt{\pi}} \cdot \sqrt{\pi} = 1$$

Como se quería demostrar.

⁷ Elige una de las dos para el tema. No creemos que aporte mucho incluir ambas.

Llamaremos a la variable aleatoria $u = N(\mu, \sigma)$ a aquella que se describe con la función de densidad anterior, que será la distribución normal.

Nótese que no podemos establecer una expresión analítica de la función de distribución, en tanto que no existe una primitiva analítica para la función e^{-x^2} . Por tanto, lo más que podemos decir es que la función de distribución de esta expresión es:

$$P[X \leq x] = F(x) = \int_{-\infty}^x \frac{1}{\sigma\sqrt{2\pi}} \exp\left[-\frac{(x-\mu)^2}{2\sigma^2}\right] dx$$

Definición: La función **normal estándar** es aquella cuya media es 0 y desviación 1, quedando la expresión como sigue:

$$f_e(x) = \frac{1}{\sqrt{2\pi}} \exp\left[-\frac{x^2}{2}\right]$$

Proposición: en la distribución normal:

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left[-\frac{(x-\mu)^2}{2\sigma^2}\right]$$

La media es μ , y la varianza σ^2 (por lo que la desviación es σ)

Demostración:

La media de una distribución continua se calcula como:

$$\mu = \int_{-\infty}^{\infty} xf(x)dx = \frac{1}{\sigma\sqrt{2\pi}} \int_{-\infty}^{\infty} x \exp\left[-\frac{(x-\mu)^2}{2\sigma^2}\right] dx$$

Cambiamos de variable:

$$z = \frac{x-\mu}{\sigma} \Rightarrow dz = \frac{1}{\sigma} dx$$

De donde:

$$\begin{aligned} I &= \frac{\sigma}{\sigma\sqrt{2\pi}} \int_{-\infty}^{\infty} (\sigma z + \mu) \exp\left[-\frac{z^2}{2}\right] dz \\ &= \frac{1}{\sqrt{2\pi}} \left[\sigma \int_{-\infty}^{\infty} z \exp\left[-\frac{z^2}{2}\right] dz + \mu \int_{-\infty}^{\infty} \exp\left[-\frac{z^2}{2}\right] dz \right] \end{aligned}$$

La primera integral es idénticamente cero, pues tenemos la integral de una función impar en un intervalo simétrico (aunque sea infinito).

Para la segunda, usamos los resultados del anterior teorema⁸ (si lo has demostrado en el tema), que tienen que ver con la gamma, además de usar el hecho de que es una integral de una función par, por lo que cambiamos los límites a $(0, \infty)$ y multiplicamos por 2:

$$\begin{aligned} t &= \frac{z^2}{2} \Rightarrow dt = zdz \Rightarrow dz = \frac{1}{z} dt \Rightarrow dz = \frac{1}{t} dt \\ I &= \frac{2\mu}{\sqrt{2\pi} \cdot \sqrt{2}} \left[\int_0^{\infty} t^{-\frac{1}{2}} \cdot \exp[-t] dt \right] = \frac{\mu}{\sqrt{\pi}} \left[\int_0^{\infty} t^{-\frac{1}{2}} \cdot \exp[-t] dt \right] \end{aligned}$$

Que es una gamma con $p = \frac{1}{2}$ (ver demostración anterior si no se ha puesto en el tema):

⁸ Si ya lo demostraste, puedes saltarte casi la totalidad de lo que queda de demostración, usando los resultados anteriores.

$$I = \frac{\mu}{\sqrt{\pi}} \cdot \Gamma\left(\frac{1}{2}\right) = \frac{\mu}{\sqrt{\pi}} \cdot \sqrt{\pi} = \mu$$

Como se quería demostrar.

En cuanto a la desviación, demostraremos que la varianza es σ^2 :

$$\text{Var}(X) = E(X^2) - E(X)^2 = \int_{-\infty}^{\infty} (x - \mu)^2 \cdot \frac{1}{\sigma\sqrt{2\pi}} \exp\left[-\frac{(x - \mu)^2}{2\sigma^2}\right] dx$$

Repetiremos los mismos pasos que antes:

$$z = \frac{x - \mu}{\sigma} \Rightarrow dz = \frac{1}{\sigma} dx$$

$$\text{Var}(X) = \frac{\sigma}{\sigma\sqrt{2\pi}} \int_{-\infty}^{\infty} \sigma^2 z^2 \cdot \exp\left[-\frac{z^2}{2}\right] dz$$

Usamos el hecho de que la integral es par y cambiamos los límites, multiplicando por 2:

$$\text{Var}(X) = \frac{2\sigma^2}{\sqrt{2\pi}} \int_0^{\infty} z^2 \cdot \exp\left[-\frac{z^2}{2}\right] dz$$

Volvemos a cambiar la variable:

$$t = \frac{z^2}{2} \Rightarrow dt = z dz \Rightarrow dz = \frac{1}{z} dt = \frac{1}{\sqrt{2t}} dt$$

Con lo que:

$$\text{Var}(X) = \frac{2\sigma^2}{\sqrt{2\pi}} \int_0^{\infty} 2t \cdot \frac{\exp[-t]}{\sqrt{2} \cdot t^{1/2}} dt = \frac{2\sigma^2}{\sqrt{\pi}} \int_0^{\infty} t^{1/2} \cdot \exp[-t] dt$$

Tenemos de nuevo una gamma, esta vez con $p = 3/2$:

$$\text{Var}(X) = \frac{2\sigma^2}{\sqrt{\pi}} \Gamma\left(\frac{3}{2}\right) = \frac{2\sigma^2}{\sqrt{\pi}} \cdot \frac{1}{2} \cdot \Gamma\left(\frac{1}{2}\right) = \frac{\sigma^2}{\sqrt{\pi}} \cdot \sqrt{\pi} = \sigma^2$$

Como se quería demostrar.

Para ver la forma que tiene esta distribución, vemos los siguientes resultados:

Proposición 1: la función es simétrica par, respecto a la media

Demostración 1: ser simétrica par respecto a la media significa que el valor de la función es el mismo al alejarse la misma cantidad a un lado u otro de la media:

$$f(\mu + x) = f(\mu - x)$$

Comprobémoslo:

$$\begin{cases} f(\mu + x) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left[-\frac{(\mu + x - \mu)^2}{2\sigma^2}\right] = \frac{1}{\sigma\sqrt{2\pi}} \exp\left[-\frac{x^2}{2\sigma^2}\right] \\ f(\mu - x) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left[-\frac{(\mu - x - \mu)^2}{2\sigma^2}\right] = \frac{1}{\sigma\sqrt{2\pi}} \exp\left[-\frac{x^2}{2\sigma^2}\right] \end{cases}$$

Proposición 2: los límites cuando x tiende a $\pm\infty$ son cero, pues la función se aproxima exponencialmente a cero. Tiene por tanto asíntota horizontal $y = 0$ tanto en infinito como en menos infinito.

Demostración 2: trivial, a la vista de la función exponencial decreciente.

Proposición 3: el valor máximo lo alcanza en $x = \mu$

Demostración 3: dado que tenemos una función definida en $\mathbb{R}$, que es derivable en todos sus puntos, los únicos máximos o mínimos deben coincidir con las tangencias horizontales. Analizamos la derivada:

$$f'(x) = \frac{-2(x - \mu)}{2\sigma^2} \cdot \frac{1}{\sigma\sqrt{2\pi}} \exp\left[-\frac{(x - \mu)^2}{2\sigma^2}\right] \Rightarrow f'(x) = -\frac{1}{\sigma^2} (x - \mu) f(x)$$

$$f'(x) = 0 \Rightarrow x = \mu$$

Ya que $f(x) \neq 0$. Además, será un máximo, pues la función es creciente hasta $x = \mu$ y decreciente en el resto.

Proposición 4: la función tiene puntos de inflexión en $x = \mu \pm \sigma$

Demostración 4: no tenemos más que analizar la segunda derivada, a partir de la primera, calculada anteriormente:


$$\frac{d^2}{dx^2}f(x) = -\frac{1}{\sigma^2}[f(x) + (x - \mu) \cdot f'(x)] = \frac{-1}{\sigma^2}\left[f(x) + (x - \mu) \cdot \frac{-(x - \mu)}{\sigma^2}f(x)\right]$$

$$\Rightarrow \frac{d^2}{dx^2}f(x) = \frac{-1}{\sigma^4}[\sigma^2 - (x - \mu)^2]f(x)$$

$$\frac{d^2}{dx^2}f(x) = 0 \Rightarrow (x - \mu)^2 = \sigma^2 \Rightarrow \boxed{x = \mu \pm \sigma}$$

Es decir, la función tiene dos puntos de inflexión que equidistan de la media en la cantidad σ .

Con toda esta información, la gráfica de la función será:



Nótese en el gráfico anterior algo importante:

- La probabilidad de encontrar la variable dentro de un intervalo de una desviación respecto a la media, es decir, $(\mu - \sigma, \mu + \sigma)$ es aproximadamente 0.68 (el 68% del área de la curva). Podemos definir esta zona como **zona de normalidad**.
- La probabilidad de encontrarla dentro de dos desviaciones es de aproximadamente 0.95.
- Si nos alejamos tres desviaciones respecto a la media, la probabilidad asciende a aproximadamente 0.997.

Esto a veces se conoce como la regla del 68-95-99.7, en tanto que representan los porcentajes de área respecto al total que ocupa la gráfica al alejarse de la media una, dos o tres desviaciones.

7.2. Tipificación de la variable

Como se ha mencionado anteriormente, no es posible encontrar una expresión analítica para la integral de la función gaussiana. Es por esto que, para poder realizar cálculos con la distribución normal sin herramientas especializadas,

usamos la **distribución normal estándar**, que es aquella con media cero y desviación 1, cuyos resultados se calculan y tabulan mediante cálculo numérico.

A partir de aquí, no tenemos más que utilizar las propiedades de la distribución para llevar a cabo un cambio de variable (una nueva variable aleatoria continua), lo que se llama **tipificación de la variable**. Veamos cómo.

Sea una variable X que se ajusta a una distribución normal $X \sim N(\mu, \sigma)$. Definamos una nueva variable aleatoria Z , que sea una transformación lineal de la anterior, de forma que:

$$Z = mX + n$$

De forma que esta variable se ajusta a $Z \sim N(m\mu + n, m\sigma)$, por propiedades de la media y la desviación. Ahora, si concretamos estos parámetros de forma que:

$$Z = \frac{1}{\sigma}X - \frac{\mu}{\sigma}$$

Vemos que esta variable se ajusta a $N(0,1)$, la normal estándar, que ya definimos previamente como:

$$f_e(x) = \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{x^2}{2}\right)$$

Proposición: el cambio de variable:

$$z = \frac{x - \mu}{\sigma}$$

Transforma la distribución normal, en una distribución normal estándar, de media 0 y desviación 1.

Demostración:

$$\frac{1}{\sigma\sqrt{2\pi}} \exp\left[-\frac{(x - \mu)^2}{2\sigma^2}\right] \underset{\substack{z = \frac{x - \mu}{\sigma} \\ x = \sigma z + \mu}}{=} \frac{1}{\sigma\sqrt{2\pi}} \exp\left[-\frac{(\sigma z + \mu - \mu)^2}{2\sigma^2}\right] = \frac{1}{\sigma\sqrt{2\pi}} \exp\left[-\frac{z^2}{2}\right]$$

Para que cumpla las propiedades de función de distribución, debe cumplirse que:

$$\int_{-\infty}^{\infty} f(x) dx = 1$$

Pero ya vimos que:

$$\int_{-\infty}^{\infty} \frac{1}{\sqrt{2\pi}} \exp\left[-\frac{z^2}{2}\right] dz = 1$$

Ya que es una particularización de la normal, con $\mu = 0$ y $\sigma = 1$, así que, en la expresión anterior, vemos finalmente que σ debe ser 1 para cumplir todo esto.

Así pues, el cambio de variable que realizaremos para transformar una distribución normal $N(\mu, \sigma)$ en una normal estándar $N(0,1)$ será:

$$Z = \frac{X - \mu}{\sigma}$$

Que se llama **tipificación de la variable**, y permite calcular cualquier probabilidad de cualquier distribución normal, a través de la distribución normal estándar. Nótese que, al ser un cambio de variable, la probabilidad calculada en la distribución original y la calculada con la transformación deben ser, lógicamente, iguales.

7.3. Teorema central del límite

Teorema central del límite (versión Lyapunov⁹)¹⁰: si $X_1 \dots X_n$ es un número grande de variables aleatorias independientes con media $E[X_i] = \mu_i$ y varianza dada por $VAR[x_i] = \sigma_i^2$, entonces la variable

$$Y = \sum_i X_i$$

sigue una normal $N(\mu, \sigma)$ con:

$$\mu = \sum \mu_i, \quad \sigma = \sqrt{\sum \sigma_i^2}$$

7.4. Aproximación de la binomial por la normal

Teorema de deMoivre-Laplace¹¹

Una binomial $B(n, p)$ se aproxima a una normal $N(\mu, \sigma)$ con $\mu = np$ y $\sigma = \sqrt{npq}$, cuando se tiene un número n grande. La aproximación será tanto mejor, cuanto mayor sea el producto np y nq .

De forma general, se acepta como buena aproximación, siempre que tanto np como nq (siendo $q = 1 - p$) sean mayores que 3, y se entenderá como muy buena aproximación siempre que sean mayores que 5.

Además, se aplica la **corrección de continuidad o corrección de Yates**, para calcular valores puntuales de una distribución binomial haciendo uso de la normal. Esta corrección consiste en sumar o restar 0.5 a la variable, por la aproximación como un área continua resultante de un área original formada por rectángulos. Así, de forma general, si tenemos una binomial $B(n, p)$ aproximada por una normal $N(\mu, \sigma)$, y llamando P_B a la probabilidad de la binomial (sin aproximar), y P_N a la probabilidad aproximada:

$$\begin{cases} P_B(x \leq k) \approx P_N(x < k + 0.5) & P_B(x \geq k) \approx P_N(x > k - 0.5) \\ P_B(x < k) \approx P_N(x < k - 0.5) & P_B(x > k) \approx P_N(x > k + 0.5) \\ P_B(x = k) \approx P_N(k - 0.5 < x < k + 0.5) \end{cases}$$

Como vimos en el tema anterior, la distribución binomial consiste en una variable discreta $X \sim B(n, p)$, que consiste en la realización de n experimentos dicotómicos, con probabilidad de éxito p . En la vida cotidiana, casi todo es dicotómico o puede aproximarse por tal, desde cuestiones científicas, sociológicas, ingenieriles, etc. Ahora bien, lo más frecuente es que tengamos un número tan grande de experimentos dicotómicos, que el cálculo mediante las expresiones de la

⁹ El TCL en esta versión de Lyapunov es una generalización del TCL, que establece las condiciones para que la suma de variables independientes converja a una normal. La condición de Lyapunov garantiza la rápida convergencia a través del rápido crecimiento de la varianza total, frente a las pequeñas contribuciones individuales de cada variable aleatoria, o lo que es lo mismo, que ninguna variable aleatoria individual domine frente a otras. Como aplicación, por ejemplo, en teoría de errores, este teorema implica que si se suman errores pequeños a la hora de medir magnitudes similares, el error total tiende a una distribución normal.

¹⁰ NOTA: sugerencia de demostración, en caso de que se disponga de tiempo

¹¹ NOTA: puede ser interesante demostrar este teorema o el del apartado siguiente. Aunque el tema no indica expresamente el teorema central del límite, conviene mencionarlo, al igual que el de deMoivre. Puede incluirse esta demostración, aunque son más interesantes aquellas relacionadas con la propia distribución normal.

distribución binomial sea inabordable. Por poner un ejemplo, la configuración del ADN es, esencialmente, la de pares de bases nitrogenadas, A-T y G-C, pero tenemos cientos de miles de millones de moléculas. El análisis de alguna característica poblacional (enfermo-no enfermo, trabajador-no trabajador, etc.), es una variable dicotómica, pero al estudiar miles o millones de personas, los cálculos se vuelven demasiado complejos.

Ahora bien, el teorema de deMoivre mencionado anteriormente, nos permite aproximar una distribución binomial por una normal. Esto será especialmente útil cuando tengamos distribuciones binomiales, en las que se pregunte por un rango (intervalo) de éxitos, en vez de un número puntual de los mismos. Veamos un ejemplo de ello.

Ejemplo 1: calcular la probabilidad de que, en un examen de 100 preguntas tipo test, con tres respuestas cada una y solo una correcta, se acierten exactamente 70 preguntas.

Este es el ejemplo en que NO es necesaria la aproximación. Este experimento se ajusta a una normal $B\left(100, \frac{1}{3}\right)$, de forma que:

$$P(X = 70) = \binom{100}{70} \cdot \left(\frac{1}{3}\right)^{70} \cdot \left(\frac{2}{3}\right)^{30} = \dots = 6.12 \cdot 10^{-14}$$

Ejemplo 2: calcular la probabilidad de aprobar el test anterior, entendiendo el aprobado como obtener 50 o más correctas.

En este caso, se pide $P(X \geq 50)$. Para llevar a cabo esta operación, deberíamos calcular 51 expresiones como la anterior:

$$P(X \geq 50) = \sum_{k=50}^{100} \binom{100}{k} \cdot \left(\frac{1}{3}\right)^k \cdot \left(\frac{2}{3}\right)^{100-k}$$

Lo cual es un cálculo interminable. Ahora, con el teorema de deMoivre:

$$\begin{cases} \mu = 100 \cdot \frac{1}{3} = 33.33 \\ \sigma = \sqrt{npq} = 4.71 \end{cases} \Rightarrow X \sim N(33.33, 4.71)$$

Con esto, bien sea a través de la tabla de la distribución normal estándar, o bien a través de una calculadora de distribución normal¹², y con la corrección de continuidad, llegamos a:

$$P_B(X \geq 50) \approx P_N(X > 50 - 0.5) = 0.0003$$

Con una calculadora de binomial¹³, el resultado sería 0.0004.

La aproximación es razonablemente buena, en tanto que $np = 33.33 \gg 5$, y a su vez $nq = 100 \cdot \frac{2}{3} = 66.67 \gg 5$.

8. Aplicaciones

La distribución normal aparece en todos los campos de las ciencias puras y sociales. Lo mismo sirve para estudiar la superdotación¹⁴ (que se puede ajustar,

¹² Puedes acceder a una calculadora de distribución normal en este [enlace](#).

¹³ Puedes acceder a una calculadora de distribución binomial en este [enlace](#).

¹⁴ Existe mucha controversia con esto. A fin de cuentas, ¿qué es la inteligencia? Para poder medir la inteligencia numéricamente hay que elaborar unos tests (tests de inteligencia), que son y han sido cuestionados ampliamente. Ahora bien, eso no quita para que, intuitivamente, sea relativamente razonable pensar que la mayor parte de la población tenga una inteligencia promedio (signifique lo que signifique la inteligencia), y

digamos, a una normal de media 100 y desviación 10), que al estudiar el efecto de un medicamento (que se puede ajustar, digamos, a una normal de media 6 y desviación 2, es decir, hace efecto durante unas seis horas con un margen de normalidad de 2 horas). Sin embargo, dado que casi cualquier fenómeno real se puede representar por una dicotomía (éxito o fracaso), y que habitualmente estos fenómenos se producen de manera masiva, la mayor parte de los fenómenos sociales o científicos son representables por distribuciones binomiales que, aproximadamente, son distribuciones normales. Veamos algunos modelos:

- Manifestaciones (sociología). Podemos fijarnos como variables en el buen/mal comportamiento de los manifestantes, si proclaman algo o no, si están de acuerdo o no... todo ello dicotomías multiplicadas por un número grande de manifestantes. Las redes sociales actuales funcionan como generadoras de dicotomías, sobre todo si atendemos a los algoritmos, que polarizan a la población a base de recomendaciones de aquellas cosas que ya sigues. Por ejemplo, si a un individuo le gusta la música rock, los algoritmos le sugerirán cada vez más rock, y menos reggaetón. Pero al que le gusta el reggaetón, contrariamente, le parecerá extraño que a alguien le guste el rock, porque todo lo que ve en sus redes sociales, repositorios musicales, etc., es reggaetón. Lo mismo se aplica a gustos, cocina, política, películas o series.
- Biología: el propio ADN tiene bases nitrogenadas que aparecen por pares (adenina-timina y citosina-guanina), repetidas un número enorme de veces. Es por esto que la mayor parte de los procesos biológicos pueden representarse por distribuciones normales.
- Procesos de fabricación: las piezas mecánicas (o cualquier fenómeno similar), pueden modelizarse en base a si están o no rotas, si funcionan o no, o si es necesario o no reponerlas. Todos ellos experimentos dicotómicos multiplicados cientos de miles de veces, por lo que seguirán distribuciones normales.
- Teoría de errores: el gran logro de Gauss con la teoría de la normal fue utilizarla para el pronóstico de errores trabajando con datos astronómicos. Los errores suelen tener una cierta media y se propagan de forma simétrica a ambos lados de la misma (la misma probabilidad se tiene de cometer un error de medida de 1cm por debajo o por encima de la medida real).
- TCL para medias muestrales. Si se tiene un número grande de muestras, se puede utilizar el teorema central del límite para ver que la media de las medias muestrales, suponiendo que vengan de distribuciones normales, acaba siendo una normal, pero esta vez de parámetros $N\left(\mu, \frac{\sigma}{\sqrt{n}}\right)$

Se ve claramente que, si se toman muchas muestras, la distribución de la media de las mismas tiene una distribución normal con desviación cero, es decir, puede decirse casi con seguridad que la media de las muestras será la predicha.

a medida que nos alejamos a ambos lados, por arriba o por abajo, disminuye el número de individuos.

9. Conclusión

En sus problemas iniciales, Abraham y Carl se dan cuenta que ambos están trabajando con distribuciones normales. El primero, de una forma empírica: si el estudio promedio es de 25 minutos, es razonable pensar que la misma probabilidad hay de que se concentre 10 que 40 minutos, pero que la probabilidad de que su estudio sea de diez horas tiende a cero, lo mismo que que no se pueda concentrar en absoluto. Esto presupone que el estudio se aproximará a una distribución normal de media 25 y desviación 10 minutos.

Por su parte, Carl en su estudio del número de personas que se encuentran estudiando se topa con una dicotomía: o estudian o no, y son muchas personas. Esto lleva irremediablemente a una binomial que puede aproximarse a una normal por lo aprendido durante el tema, de ahí que les queden figuras similares.

Ambos están estudiando normales, que se ajustan perfectamente a sus experimentos, y que les permitirán sacar conclusiones a preguntas hechas a priori como ¿cuál es la probabilidad de que haya simultáneamente 35 de sus amigos estudiando? O ¿cuál es la probabilidad de que la población se concentre más de 20 minutos?

10. Bibliografía

- Ross, Sheldon (2008) *First Course in Probability, A:International Edition*, Prentice Hall.
- Strogatz, Steven. (1º edición, 2013). *The joy of X*. Mariner books
- Apuntes temarios oposición.

11. Posibilidades de ampliación

- Al igual que en el tema anterior, de toda la axiomática de la probabilidad inicial, puede ampliarse lo que se considere, existiendo numerosos teoremas, lemas, etc.
- Al igual que el tema anterior (ver posibilidades de ampliación), puede hablarse de algunos resultados interesantes que completen el tema, según el conocimiento de cada uno, como la desigualdad de Markov o la de Tchebyshev, aunque quizá no sean propios de este tema.
- Hay otros parámetros en una distribución de los que no se habla, pero que se podrían introducir, como son los de asimetría y los de curtosis, relacionados con momentos de orden superior.
- Al igual que en el tema anterior (se remite a las posibilidades de ampliación del mismo), puede definirse la función generadora de momentos, para de ahí extraer los parámetros de la distribución. Por ejemplo, para la distribución normal, esta función acaba siendo:

$$M(t) = E[e^{tX}] = e^{t\mu} \int_{-\infty}^{\infty} e^{t(x-\mu)} \cdot \frac{1}{\sigma\sqrt{2\pi}} \cdot e^{-\frac{1}{2\sigma^2}(x-\mu)^2} dx$$

Que acaba siendo, después de mucho cálculo:

$$M(t) = \exp\left(t\mu + \frac{t^2\sigma^2}{2}\right)$$

Que, efectivamente, si la derivamos y evaluamos en cero:

$$M'(t) = \exp\left(t\mu + \frac{t^2\sigma^2}{2}\right) \cdot (\mu + t\sigma^2)$$

Evaluada en cero:

$$M'(0) = \mu$$

Como debía ser.

- Existen otras distribuciones continuas conocidas, que consideramos no tienen cabida en el tema, a saber: distribución uniforme continua (se menciona en un ejemplo), distribución gamma y beta, distribución exponencial, de Cauchy, logarítmica normal, chi cuadrado, t de Student, distribución F, de Pareto, de Laplace... Quizá, y esto tendrás que valorarlo, puedes mencionar brevemente alguno de estos nombres en el tema, pero posiblemente no puedas desarrollar ninguna de ellas.
- En el tema no se demuestra el teorema central del límite. Como se indica en el texto, el tema no lo pide en el enunciado, pero si uno sabe la demostración, puede incluirla.
- Tampoco se incluye el teorema de adición, que esencialmente habla de que la suma de dos variables normales, también se comporta como una normal si se trata de variables independientes, y en este caso la distribución resultante de las distribuciones $X \sim N(\mu_X, \sigma_X)$ e $Y \sim N(\mu_Y, \sigma_Y)$ será una distribución:

$$Z \sim N\left(\mu_X + \mu_Y, \sqrt{\sigma_X^2 + \sigma_Y^2}\right)$$

No se ha incluido por su vinculación, en la demostración, con los momentos y la función generadora de momentos. Este teorema puede generalizarse a una combinación lineal de distribuciones normales.

- Este es un resultado muy interesante para definir el número π bajo la perspectiva de la probabilidad. En realidad, utiliza el método de Montecarlo, que tiene que ver con la generación de números aleatorios para resolver problemas. En este caso, diremos que “se define el número π como 4 veces la probabilidad de acertar en un círculo inscrito en un cuadrado”, aunque se puede plantear de otras formas más imaginativas. Asumiendo que la probabilidad de acertar en cada punto de un cuadrado es la misma (distribución uniforme), se tiene que:

$$P = \frac{\text{Área eficaz}}{\text{Área total}} = \frac{\pi r^2}{L^2} = \frac{\pi r^2}{(2r)^2} = \frac{\pi}{4}$$

Demostrando el resultado. En realidad, estamos utilizando distribuciones continuas. Para seleccionar puntos del cuadrado, debemos tomar un valor en

x y otro en y , de forma que, si colocamos un vértice del cuadrado en el origen, y otros dos en los ejes de coordenadas, con un lado L :

$$f(x) = \begin{cases} k & x \in [0, L] \\ 0 & x \notin [0, L] \end{cases}$$

Y lo mismo con y . Como vimos en el tema, para que sea distribución, debe cumplirse que $k = L$, de forma que:

$$\int_{-\infty}^{\infty} k \cdot dx = \int_0^L k \cdot dx = k \cdot L = 1 \Rightarrow k = \frac{1}{L}$$

@VConce